

Credit Card Data Balance

Utforskning av credit card data balance, en regressionsstudie av kund balanser med avseende på income, cards, limit, age, rating, education, region, student, own, married.

Inledning

Detta projekt är tänkt att ge ett potentiellt underlag för banker i beslutsfattande kring kundernas kreditkort genom att bidra till en ökad förståelse för vilka faktorer som har en korrelation med kundernas spenderingsvanor via kredit. Detta planeras att utföras genom att öka förståelsen kring korrelationen mellan genomsnittlig kreditkortsbalans och en handfull faktorer, varav en del är demografiska och en del är bankerelaterade. Detta planeras åstadkommas genom att noggrant framställa visualiseringar av relevant data från 400 kunder samt att utföra regressionsanalyser och sedan utforska prediktionsmodeller i ändamålet att därigenom ge den bästa möjligheten att prediktera *Balance* för framtida potentiella kunder.

Genomförandet av detta projekt är betydande av ett flertal skäl. Informationen som utforskas i detta projekt visar på korrelationer som kan komma att ligga till grund för framtida undersökningar kring kausalitet. Projektet ger även möjligheten till att prediktera vad framtida kunders genomsnittliga kreditkortbalans kan komma att vara och därigenom bidrar då även till bankens potentiella beslutsfattanden kring nya kunder.

Datan som används i detta projekt är *Credit* datasetet från *ISLR2* som visar kreditkortrelaterad data från 400 observationer.

Beroende variabel: *Balance* (*Y*)

Oberoende variabler: *Income, Cards, Limit, Age, Rating,*

Education, Region, Student, Own, Married (*X*) (för lista med förklaring av variabler, se appendix).

Syfte och frågeställning


Syftet med detta projekt är att undersöka korrelationer mellan ett flertal relevanta faktorer och bankkunders genomsnittliga kreditkortsbalans. Ytterligare så ämnar detta projekt att så nära som möjligt kunna prediktera framtida bankkunders genomsnittliga kreditkortsbalans baserat på dessa tidigare nämnda faktorer.

Baserat på detta, är projektets frågeställning:

Vilka faktorer har ett signifikant samband med kundernas genomsnittliga kreditkortsbalans och hur stort är sambandet?


Visualisering, metoder samt motivering

När det kommer till val av visualisering, så har en handfull olika grafer tillämpats för att påvisa intressanta iakttagelser såväl som jämföra och visa på olika fördelningar.




Graf 1

Inledningsvis så användes *Graf 1* som ett verktyg i ändamål att snabbt ge en visuell bild av potentiellt intressanta faktorer, där det finns möjlighet för korrelation med *Balance*. Första iakttagelsen gör det svårt att säga någonting om exempelvis de dikotoma faktorerna som *Own*, *Student* och *Married*. *Cards*, *Age* och *Education* står inte heller nödvändigtvis ut baserat på *Graf 1*. Däremot så framstår det sig vara en tydlig korrelation mellan *Balance* och både *Limit* samt *Rating*. Ytterligare en potentiellt intressant variabel är *Income* som kan anses vara värd att titta närmare på




Graf 2

Graf 2 visar tydligare på den potentiella korrelationen mellan Income och Balance. Något som dock är värt att notera är antalet observationer som visar en genomsnittlig kreditkortsbalans på 0. Detta projekt ämnar att utforska kring kreditkortsbalans och därav är dessa observationer relativt irrelevanta för ändamålet och kan potentiellt vara störande. Valet görs därför att endast iaktta de observationer med en *Balance* över 0.




Graf 3




Graf 4

Graf 3 visar på inkomstfördelningen bland de nu 310 observationerna (90 observationer har exkluderats då de hade en *Balance* på 0). Det framgår tydligt att inkomsten inte är normalfördelad och därför så har *Income* logaritmerats som kan ses i *Graf 4*. Detta görs delvis för att minska den potentiella påverkan av uteliggar-variabler på den kommande modellen.



Graf 5



Graf 6

Graf 5 visar på skillnaden i inkomstfördelningen (logaritmerad) mellan de observationer som aktivt studerar och de som inte gör det. Det framgår inga markanta skillnader i grafen. Det framstår att de som aktivt studerar tenderar att tjäna lite mindre i var respektive kvartil jämfört med de som inte aktivt studerar vilket bör kunna förklaras baserat på bland annat tillgänglig tid. Det är värt att nämna att ingen av observationerna har en inkomst på \$0. Den relativt jämna inkomstfördelning sätts dock i perspektiv av *Graf 6* som visar på skillnaderna i fördelning av genomsnittlig kreditkortbalans hos aktivt studerande och icke-studerande. Även om det existerar ett fåtal extremvärden som sticker ut bland de icke-studerande så är det tydligt att de aktivt studerande tenderar att ha betydligt högre genomsnittlig kreditkortsbalans. Detta kan mycket väl vara relaterat till de höga kostnaderna associerade med att studera i de Förenta Staterna.

Residuals:

Min	1Q	Median	3Q	Max
-472.86	-70.02	15.19	84.18	218.83

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	530.7054	58.4962	9.072	< 2e-16	***
Income_log	-367.4137	15.0730	-24.376	< 2e-16	***
Limit	0.3380	0.0456	7.412	1.29e-12	***
Rating	-1.0139	0.6725	-1.508	0.132710	
Cards	24.2883	5.6927	4.267	2.67e-05	***
Age	-1.3766	0.4045	-3.403	0.000757	***
Education	-1.2298	2.1594	-0.570	0.569437	
OwnYes	10.9627	13.6717	0.802	0.423276	
StudentYes	459.9830	21.2592	21.637	< 2e-16	***
MarriedYes	-18.6975	14.3283	-1.305	0.192921	
RegionSouth	13.8034	16.6802	0.828	0.408595	
RegionWest	5.1275	19.6905	0.260	0.794733	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 119.4 on 298 degrees of freedom

Multiple R-squared: 0.9197, Adjusted R-squared: 0.9167

F-statistic: 310.3 on 11 and 298 DF, p-value: < 2.2e-16

Regression 1

Regression 1 visar alla oberoende variabler och dess respektive korrelationer med *Balance* (efter att variablerna där *Balance* är 0 tagits bort samt att *Income* har logaritmerats). Baserat på denna regression så har det inkluderats en handfull icke-signifikanta variabler. Dessa variabler tagits bort i *Regression 2*.

Residuals:

Min	1Q	Median	3Q	Max
-473.23	-64.15	14.48	85.78	207.49

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.907e+02	4.361e+01	11.252	< 2e-16	***
Income_log	-3.653e+02	1.500e+01	-24.357	< 2e-16	***
Limit	2.692e-01	5.188e-03	51.898	< 2e-16	***
Cards	1.993e+01	4.786e+00	4.165	4.06e-05	***
Age	-1.409e+00	4.029e-01	-3.498	0.000539	***
StudentYes	4.583e+02	2.078e+01	22.060	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 119.4 on 304 degrees of freedom

Multiple R-squared: 0.9181, Adjusted R-squared: 0.9168

F-statistic: 681.7 on 5 and 304 DF, p-value: < 2.2e-16

Regression 2

Enligt tabellen, *Regression 2*, så är residualerna för regressionen potentiellt oroväckande då skillnaden i magnitud mellan minimivärde och maxvärde visar på problem med extremvärden. Denna effekt är inte lika uttrycklig när det kommer till kvartil 1 och 3. Det kan dock argumenteras att medianen är relativt nära 0 vilket ändå bådär positivt för modellen.

Interceptet, vilket är den förväntade genomsnittliga kreditkortsbalansen om alla oberoende variabler skulle vara 0, visar på cirka \$490,7 (detta är alltså för observationerna med över 0 i *Balance*). *Income_log* som koefficient visar på cirka -365 har drastiskt ändrats från det potentiella positiva sambandet med *Balance* som visualiserades i graf 2 men den är tydligt signifikant på 5% nivå. Förklaringen till denna skillnad ligger inte i logaritmeringen av variabeln. Anledningen skulle kunna vara relaterad till att *Income* kanske helt enkelt inte är oberoende från de andra variablerna och att det redogörs i regressionen.


Cards, *Age*, *Student* och *Limit* visar sig vara signifikanta på 5% nivån och korrelerar med 19,93; -1,41; 458; 0,27 respektivt. Generellt sett förklarar modellen 91,68% av variationen i den beroende variabeln och modellen är signifikant på 5% nivå.

Prediktionsmodeller (Ridge och Lasso):


En jämförelse av prediktiva modeller har genomförts baserat på *Regression 2* där OLS, Ridge och LASSO har undersökts. Out of sample “root mean squared percentage error” (rMSPE) som har visats är cirka 129,64 för OLS; 150,13 för Ridge; 129,33 för LASSO.

Resultat i sin helhet visar att LASSO regression är den mest relevanta prediktiva modellen med en out of sample rMSPE på cirka 129,33. Dock så framstår skillnaden mellan LASSO och OLS inte speciellt anmärkningsvärd.

Ridge regression visas i Graf 7,8




Graf 7




Graf 8

Lasso regression visas i graf 9,10



Graf 9



Graf 10

Resultat och diskussion av resultat

Resultat

Den utförda regressionsanalysen som undersökte hur kundernas genomsnittliga kreditkortsbalans korrelerar med olika demografiska och bankrelaterade faktorer visade i slutändan en signifikant korrelation med 5 variabler. Variablerna och dess koefficienter är som följer:

Income_log: -365

Limit 0,27

Card: 19,93

Age: -1,41

Student: 458

Diskussion av resultat

Av dessa så är det två variabler som sticker ut och det är *Income_log* och *Student*. De båda är starkt korrelerade med *Balance* men åt separata håll. Det finns några relativt intuitiva anledningar som skulle kunna ligga bakom dessa resultat. Med en ökad inkomst så torde det vara rimligt att anta minskade behov för att "låna" pengar och som aktivt studerande i de Förenta Staterna så är det ett minst lika rimligt antagande att behovet för att "låna" pengar skulle öka. Som påpekades i relation till *Graf 5* och *Graf 6* så går det även att påpeka relativt små men tydliga skillnader kring inkomsten mellan aktivt studerande och icke-aktivt studerande. *Limit* framstår att ha en mycket liten koefficient, *Age* negativa korrelation kan spekuleras att det har att göra med den minskade risktolerans som kommer med högre ålder. Slutligen så är *Card* en variabel som kan resoneras kring. Det kan argumenteras att chansen lär vara högre att någon som använder kreditkort mer (har en högre genomsnittlig kreditkortsbalans) kanske också är mer trolig att ha fler kreditkort och vise versa.

Slutsatser

Detta projekt ämnade att undersöka olika demografiska och bankspecifika faktorer för att se om, och i så fall hur mycket de korrelerar med bankkunders genomsnittliga kreditkortsbalans. Datan utforskades visuellt, i form av olika grafer, samtidigt som den anpassades i ändamål för att skapa en bättre och mer representativ modell. Detta resulterade i uteslutandet av observationer med en *Balance* på 0 samt logaritmeringen av variabeln *Income*. Sedan utfördes regressionsmodeller fram tills att endast variabler med ett signifikant samband var kvar i modellen. Dessa var *Income_log*, *Limit*, *Card*, *Age* och *Student*. Sedan utfördes även en jämförelse av prediktionsmodeller där LASSO regression visade sig mest passande men med en liten skillnad gentemot OLS. En diskussion kring potentiella anledningar och relevanta tankar kring resultaten utfördes slutligen.

Detta projekt kan ligga som en grund för beslutsfattande av banker kring deras hantering av kreditkortskunder. Däribland nya kunder med hjälp av den presenterade predikteringen. Trots att projektet inte kan påvisa något påverkanssamband så framgår det tydligt en handfull korrelerade variabler som kan vara värda för banker att diskutera kring, forska vidare på eller i alla fall att ha i åtanke när det kommer till kunder och deras genomsnittliga kreditkortsbalans.

Appendix

R kod:

#Ladda in

```
library(ISLR2)
library(tidyverse)
library(ggplot2)
library(glmnet)
data(Credit)
```

#Ta bort Balance 0 och logaritmera Income

```
creditno0 <- subset(Credit, Balance > 0)
creditno0$Income_log <- log(creditno0$Income)
```

#Graf 1

```
plot(Credit)
```

#Graf 2

```
Credit %>%
  ggplot(aes(Income, Balance,)) +
  geom_point(alpha = .6,
             colour = "blue") +
  labs(y = "Genomsnittlig kreditkortsbalans",
       x = "Inkomst")
```

#Graf 3

```
creditno0 %>%
  ggplot(aes(Income)) +
  geom_histogram(binwidth = 4,
                 alpha = 0.6,
                 fill = "blue") +
  labs(title = "Inkomstfördelning",
       subtitle = "Räknat i 1 000's $",
       y = "Observations",
       x = "Income")
```

#Graf 4

```
creditno0 %>%
  ggplot(aes(Income_log)) +
```

```
geom_histogram(binwidth = .045,  
  alpha = 0.6,  
  fill = "blue")+  
labs(title = "Inkomstfördelning",  
  subtitle = "Logaritmerad")
```

#Graf 5

```
creditno0 %>%  
  ggplot(aes(Student,  
    Income_log,  
    fill = Student))+  
  geom_violin(show.legend = FALSE)+  
  geom_boxplot(show.legend = FALSE, width = .3)+  
  labs(title = "Inkomstfördelning, student ja/nej",  
    y = "Income_log",  
    x = "Student")
```

#Graf 6

```
creditno0 %>%  
  ggplot(aes(Student,  
    Balance,  
    fill = Student))+  
  geom_violin(show.legend = FALSE)+  
  geom_boxplot(show.legend = FALSE, width = .3)+  
  labs(title = "Kreditkortsbalanse bland studerande och icke studerande",  
    subtitle = "Genomsnittligen räknat i $",  
    y = "Balance",  
    x = "Student")
```

#Jämförelserna

#OLS

32424 -> seed

```
set.seed(32424)
train <- sample(1:nrow(creditno0), nrow(creditno0)/2)
test <- (-train)

y_train <- creditno0[train,"Balance"]
y_test <- creditno0[test,"Balance"]

small <- creditno0[,c("Balance","Income_log","Limit","Cards","Age","Student")]

small_train <- data.frame(y_train, model.matrix(Balance ~ ., small[train,])[, -1])
dim(small_train)

x_small_test <- data.frame(model.matrix(Balance ~ ., small[test,])[, -1])
dim(x_small_test)

ols_pred <- predict.lm(ols_mod, newdata=x_small_test)

sqrt(mean((ols_pred-y_test)^2))
```

#Ridge

```
x_small_train <- small_train[, -1]
```

```
ridge.mod = glmnet(x_small_train, y_train, alpha=0)
dim(coef(ridge.mod))
```

#Graf 7

```
plot(ridge.mod)
```

```
set.seed(32424)
cv.out <- cv.glmnet(as.matrix(x_small_train), y_train, alpha=0)
```

#Graf 8

```
plot(cv.out)
ridge.lambda <- cv.out$lambda.min
```

```
ridge.pred = predict(ridge.mod, s=ridge.lambda, newx=as.matrix(x_small_test))
```

```
out <- glmnet(as.matrix(x_small_train), y_train, alpha=0)
```

```
ridge.coef <- predict(out, type="coefficients", s=ridge.lambda)
ridge.coef
```

```
sqrt(mean((ridge.pred-y_test)^2))
```

#LASSO

```
lasso.mod=glmnet(x_small_train,y_train,alpha=1)
dim(coef(lasso.mod))
```

#Graf 9

```
plot(lasso.mod)
```

```
set.seed(32424)
```

```
cv.out <- cv.glmnet(as.matrix(x_small_train),y_train,alpha=1)
```

#Graf 10

```
plot(cv.out)
```

```
lasso.lambda <- cv.out$lambda.min
```

```
#
```

```
lasso.pred=predict(lasso.mod,s=lasso.lambda,newx=as.matrix(x_small_test))
```

```
#
```

```
out <- glmnet(as.matrix(x_small_train),y_train,alpha=1)
```

```
#vet inte om det behövs
```

```
lasso.coef <- predict(out,type="coefficients",s=lasso.lambda)
```

```
lasso.coef
```

```
sqrt(mean((lasso.pred-y_test)^2))
```

Variabler och definition:

Income = inkomst i 1 000tals dollar: Kvantitativ, kontinuerlig

Limit = kreditgräns: Kvantitativ, diskret

Rating = kreditbetyg: Kvantitativ, diskret

Cards = antal kreditkort: Kvantitativ, diskret

Age = ålder i år: kvantitativ, diskret

Education = Utbildning i år: Kvantitativ, diskret

Own = nej (1) eller ja (2) ifall de äger ett hus: Kvantitativ, diskret

Student = nej (1) eller ja (2) ifall de är en student just nu: kvantitativ, diskret

Married = nej (1) eller ja (2) ifall de är gifta: Kvantitativ, diskret

Region = East (1), south (2) and west (3): Kvantitativ, diskret

Balance = genomsnittlig kreditkortsbalans i dollar: Kvantitativ, kontinuerlig